(a) 分层失效治理谱系 (Layered Mitigation)

第7.1–7.3节 | 训练时参数硬化、推理时流水线拦截与系统沙箱隔离

1. 训练时权重硬化层 (Training-Time Parametric Hardening)

红队失效样本
诱导越狱与利用提示
执行失效轨迹归档
WildTeaming, AdvBench

→ **覆盖导向配比**
危害意图聚类分流
配比采样平衡效用
TRIDENT, DiveR-CT

→ **动态对抗微调**
轮番对抗样本生成
对抗样本自适应重训
MART, R2D2 pool

→ **内生强化权重**
表征流形安全对齐
原生防御基模输出
Safe-RLHF, BeaverTails

参数微调直接重塑底层模型表征分布，提升内生鲁棒性

2. 推理时流水线拦截网关 (Inference-Time Guardrail Gateways)

输入防护网关
意图前置过滤与分类
困惑度过滤与随机平滑
拦截恶意 Token
LlamaGuard, SmoothLLM

→ **解码表征干预**
激活向量引导干预
Token 概率分布调优
动态抑制越狱倾向
Representation Steering

→ **输出合规审查**
生成后意图违规审查
后处理修正与遮蔽
有害输出阻断撤回
Self-Defense, AutoDefense

→ **合规安全响应**
验证合规安全输出
标准安全拒答或澄清
基座参数免重新训练
Guarded Deployment

在输入端、解码流与输出端设置三重检查卡口，不修改基座参数即时拦截攻击

3. 系统级沙箱与特权隔离防护 (System Sandboxing)

不可信上下文
外部检索与记忆状态
第三方工具调用返回值
Indirect Injections

→ 安全沙箱硬隔离边界 (Sandbox Boundary)

特权边界隔离
控制面与数据面
严格通道隔离
CaMeL, ToolSafe

→ **动作沙箱校验**
前后置条件约束
多步断言校验
TaskShield, IsolateGPT

→ **受限系统执行**
持久状态环境隔离
原子性事务回滚
Agent Sandboxing

约束智能体自主工具调用权限与外部环境持久状态变更，防止越权滥用

全系统栈分层防御体系：训练时更新模型参数，推理时审查 Token，应用层隔离工具权限

(b) 持续评测与修复闭环飞轮

第7.4节 | 结构化失效仓库与纵向双轨安全演进

1. 失效留存与结构化仓库

红队探索引擎
自动化候选漏洞搜索
自适应攻击策略演进
APRT, TAP, GPTFuzzer

→ **失效分诊与评定**
真实执行轨迹复现
危害严重性分级量化
StrongREJECT, WildGuard

→ **结构化失效仓库**
用例种子与环境配置
执行遥测与 Trace 日志
目标版本关联元数据

固化可验证实验证据，连接失效现象与确切系统版本 (FLARE-AI, AIID)

2. 双轨持续评测机制

轨道 A: 历史基准确定性回归重放与漂移审计

固定历史基准库
归档高危失效测试集
受控确定性用例集

→ **新版本确定性重放**
针对新目标全量复测
受控环境一致性重放

→ **安全漂移回归审计**
监测已修复漏洞复现
量化跨版本安全退化

轨道 B: 面向演进防御的自适应未知漏洞挖掘

演进攻击策略库
动态更新对抗变异算子
启发式与梯度搜索策略

→ **目标感知自适应探索**
定向探测加固后安全护栏
多轮交互动态绕过渗透

→ **残留未知漏洞发现**
主动暴露防御机制盲区
捕获针对新规则绕过样本

持续修复反馈回路与更新桥接 (Continuous Remediation Feedback Bridge)

遥测样本回流 (Telemetry Ingestion)
汇聚漂移用例与新生绕过 Trace
更新并丰富结构化失效资产库

防御策略演进 (Defensive Retuning)
指导基座对齐微调与偏好学习
校准运行时护栏与沙箱执行边界

双轨协同：历史回归复测防安全漂移，自适应前瞻探索挖残留盲区

纵向安全评估机制：回归重放检验跨版本稳定性，自适应挖掘主动暴露针对新防御的规避手段