(a) 评测框架执行底座

第8.1节 | 调度编排、遥测留存与回归重放

1. 评测负载摄入 (Campaign Workloads)

动态对抗引擎
自适应搜索与提示变异优化
高通量生成高危候选提示
GPTFuzzer, APRT, TAP

固定评估基准
标准化基准用例与对照基线
受控跨模型横向评测环境
HarmBench, AgentDojo

2. 核心评测执行底座 (garak, PyRIT, Inspect)

目标适配器
模型 API 封装与运行抽象
promptfoo, garak

攻击编排调度器
多轮状态机与调用预算
PyRIT, ARTKIT, EasyJailbreak

执行运行时与环境沙箱
隔离工具调用沙箱与智能体执行轨迹记录
Inspect AI sandbox, AgentDojo

自动化裁判与评分器
大模型裁判细则、拒答分类与策略断言
WildGuard, StrongREJECT, LlamaGuard

3. 审计留存与确定性回归重放

不可变审计轨迹
环境配置、种子与执行日志
裁判推理证据与判定结果
结构化交互遥测数据留存
Inspect AI logs, PyRIT DuckDB

确定性回归重放
固定种子的新版本回归复测
跨版本安全漂移自动化检验
跨模型基准等价性检验验证
promptfoo eval, AgenticEval

不可变遥测固化实验凭据，支撑跨版本确定性审计

(b) 人机协同漏斗与裁决闭环

第8.2节 | 定性专家规约与算法高通量扩增

1. 人类专家定性规约 (Ground Truth Standards)

规范范围界定
风险分类边界
明确安全红线
STAR, Alvarado G.

本土文化语境
地方规范习俗
暗含语境意图
Going PLACES

分歧与边界建模
标注者分歧分布
争议案例仲裁
DICES, D3CODE

定性专家规约确立风险分类基准，仲裁边界歧义

2. 算法规模化扩增与初筛 (Scale Multiplier)

负载规模化扩增引擎
结构化配方引导提示变异
拓展社会语言学多样性
规模化覆盖 10,000+ 变异样例
AART, Bridging Scale Gap

自动化高通量分诊初筛
高通量并发策略合规初筛
失效模式聚类与异常隔离
过滤常规样例，提取高争议簇
WildGuard, StrongREJECT

高通量初筛分流高争议簇至专家复审

3. 专家仲裁裁决与准则持续校准 (Closed Loop)

评判准则迭代校准
动态修正安全细则与分级阈值
规范准则版本化同步
STAR, Constitutional AI feedback

裁决结论

专家定性仲裁裁决
仲裁边缘案例与标注者分歧
提纯新攻击模式与危害定义
DICES, D3CODE, Human Panels

风险清单与分类规约动态更新
经仲裁的边界案例动态更新风险登记册、评分阈值与流转规则
STAR, Alvarado Garcia et al., Going PLACES

定性裁决提纯危害特征，驱动安全评测规约持续演进

(c) 资产分级与多方协同披露

第8.3节 | 平衡透明复现性与对抗利用物扩散管控

1. 对抗资产分级访问货架 (Tiered Access)

级别一 (公开)：开放基准数据集与评测榜单 (HarmBench)

级别二 (受限)：高危利用载荷受控面向认证学者 (Fang et al.)

级别三 (扣留)：扣留武器化载荷；仅发布系统报告 (OpenAI)

依据双重用途风险与漏洞可利用性实行分级访问授权

2. 缺陷责任制与审计规约 (Audit Dimensions)

威胁模型与配置
目标版本、提示封装与查询预算

评测协议与准则
随机种子、步长与裁判判定细则

证据凭据与访问级
脱敏执行轨迹与最小复现凭据包

披露状态与排期
私密通报日期、修复验证与通告

标准化报告维度确保跨机构多方验证与合规可审计性

3. 协同漏洞披露 (CVD) 交互泳道

(FLARE–AI, CERT/CC)

红队安全审计专家

1. 缺陷提交与证据确权
受控提交脱敏交互与复现脚本

目标模型研发厂商

2. 缺陷复现评估
复现与严重度核定

3. 补丁加固开发
微调或护栏拦截规则

安全协调机构与社区公众

4. 协同发布安全通报
补丁检验后解密发布缓解方案

协同披露流水线在公开发布前完成验证缓解